

无源领域适应的综合研究

余之奇、李晶晶、杜哲凯、朱磊、沈衡涛

摘要-在过去的十年里，领域自适应已经成为迁移学习的一个被广泛研究的分支，旨在通过利用来自源领域的知识来提高目标领域的性能。传统的领域自适应方法通常假设同时访问源域数据和目标域数据，由于隐私和机密性的考虑，这在现实场景中可能不可行。因此，无源域适应（SFDA）的研究近年来受到越来越多的关注，它只利用源训练模型和未标记的目标数据来适应目标域。尽管快速SFDA工作爆炸，但该领域没有及时和全面的调查。为了填补这一空白，我们对SFDA的最新进展进行了全面的调查，并将其组织成一个基于迁移学习框架的统一分类方案。我们不是单独呈现每种方法，而是模块化每种方法的几个组成部分，以根据每种方法的复合特性更清楚地说明它们之间的关系和力学。此外，我们比较了30多种具有代表性的分类方法在Office-31、SFDA-home和VisDA上的SFDA方法的结果，以探索各种技术路径的有效性和它们之间的组合效应。此外，我们还简要介绍了SFDA和相关领域的应用。从我们对SFDA所面临的挑战的分析中，我们对未来的研究方向和潜在的设置提供了一些见解。


索引术语-领域自适应，迁移学习，计算机视觉，无数据学习。

1介绍

深度神经网络具有泛化能力，能够在监督学习任务中获得令人满意的性能。然而，由于成本和隐私问题等因素，收集足够的培训数据可能是昂贵的。例如，手动注释单个城市景观图像以进行语义分割可能需要长达90分钟。为了缓解这一问题，迁移学习[1]，[2]被提出在标签缺陷条件下实现跨域知识转移。

域自适应（DA）[3]，[4]是迁移学习的一个重要分支，重点研究了如何在标记源域数据的帮助下提高未标记目标域的性能。在独立均匀分布的条件下，域适应的最大挑战是如何减少域移，主要分为条件移、协变量移、标签移和概念移，在以往的DA调查[5]、[6]中得到了广泛的讨论。

在传统的领域适应方法中，通常假设在适应过程中可以访问源域和目标域数据。然而，这在许多应用程序中都是不现实的。一方面，由于个人隐私、保密性和版权问题，在某些情况下，原始源域数据将无法使用；另一方面，将完整的源数据集保留在一些资源有限的设备上培训是不现实的。上述问题阻碍了这一领域的进一步发展。为了放松DA方法对源数据的依赖，近年来提出了无源域自适应（SFDA）[7]，[8]，并已迅速成为



(a) UDA (b) SFDA图。1. UDA和SFDA设置的比较。

领域自适应的重点，在图像分类[9]、[10]、语义分割[11]、[12]和目标检测[13]、[14]。

如图所示，1，最显著的差异SFDA和无监督域适应（UDA）[15]，[16]是UDA模型可以训练使用源和目标域数据，而SFDA只能利用源模型初始化目标模型，然后更新它未标记的目标数据。现有的主流UDA方法可以分为两种主要类型：一种是通过设计特定的度量标准[3]、[17]、[18]来对齐源域分布和目标域分布的方法，另一种是通过对抗性学习[19]、[20]、[21]来学习域不变特征表示的方法。然而，这些主流的UDA方法并不适用于没有源域数据的场景，这突出了研究SFDA方法作为替代方案的必要性。尽管对SFDA作出了大量的努力，但还没有对所有的工作进行全面的审查，也没有对目前与SFDA有关的进展进行总结。为了填补这一空白，我们的目标是在本次调查中对SFDA的最新进展提供一个及时和全面的回顾。

在这项工作中，我们继承了现有的迁移学习

作者来自中国电子科学与技术大学计算机科学与工程学院，成都，611731。

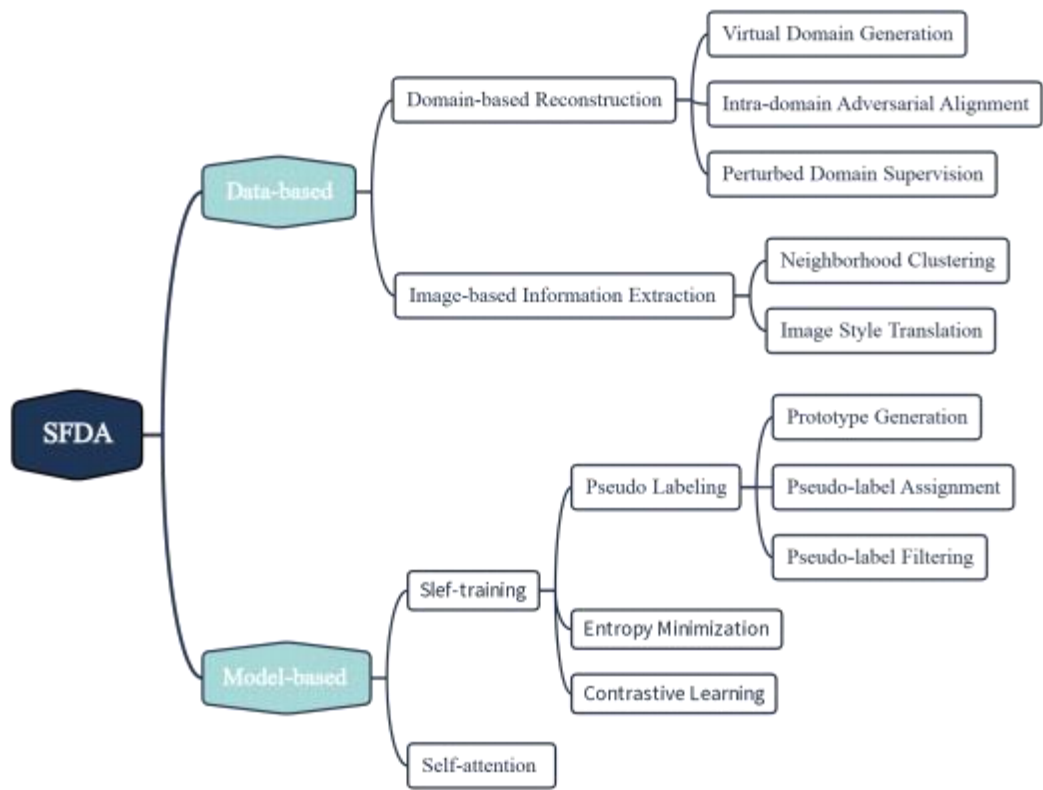


图2。SFDA方法的分类学。

调查[2]、[22]，并将SFDA分为两个方向：有数据库的方向和基于模型的方向。此外，我们发现传统的UDA方法通过对重建源域的一些额外步骤开始在SFDA设置中工作，因此我们将其作为基于领域的重建方法来反映UDA研究的可扩展性。我们在图中描述了SFDA方法的总体拓扑结构。2.

从数据中心的角度，可以看到基于领域的重构和图像风格转换

作为UDA的一些衍生品。域背后的直觉有基础的重建是非常简单的，i. e.，它的目标是重建一个域或在目标域内进行进一步的划分，以弥补丢失的源域数据，从而使UDA方法可以扩展到SFDA设置。具体地说，它可以分为虚拟域生成、域内对抗对齐和扰动域监督。图像样式转换通过源分类器的批处理归一化（BN）层将目标域数据转换为看不见的源样式，从而使目标域数据可以更好地与源模型兼容。邻域聚类是基于观察到目标数据中的底层内在结构嵌入到邻域关系中，即使目标域数据的分布不能明确地与源分类器对齐。一种假设是，目标域的每个类别都存在位于源模型边界内的邻居，因此通过保持这些硬样本之间的一致性，可以映射到源域分布。最后，基于局部结构聚类

在流形学习上，通过选择邻居节点进行[23]、[24]、[25]和聚类。

从以模型为中心的角度来看，由于源域和目标域的相似性，大多数方法都假设源预训练模型在目标域上具有一定程度的泛化。因此，可以通过探索模型在目标数据上的输出来微调模型。该自训练方案继承了半监督学习[26]、[27]、[28]的思想，可以进一步分为伪标记、熵最小化和对比学习。值得注意的是，我们进一步注意了伪标记方法，因为它是SFDA中最常用的方法。伪标记通常是通过首先对目标域内的高置信度样本进行伪标记，然后通过得到的伪标记对模型进行优化。因此，如何获得高质量的伪标签是这类方法的主要关注的问题。本文试图从各工艺为基础，从原型生成、伪标签分配和伪标签滤波等方面对该工艺路线进行了全面的技术讨论。

此外，我们观察到，大多数SFDA方法都由多个技术组件组成，每个组件可能对应于我们的分类法中的一个类别。因此，不同于以往独立处理每种工作的领域适应调查，我们的目标是模块化每种SFDA方法，并对其进行分类，以揭示不同研究方向之间的相互关系。本调查的目的是讨论SFDA的问题公式，总结该领域的当前进展，并突出SFDA技术的独特组成部分

表1
SFDA相对于其他相关设置。

	没有源数据	源模型	未标记的目标	额外的源信息	无培训
无数据KD	v	—	—	—	x
联邦DA	x	v	v	x	x
零射DA	x	v	x	x	x
测试时间DA	v	v	v	x	v
源松弛DA	v	v	v	v	x
无源DA	v	v	v	x	x

提供对这一领域的全面理解，并激发更多的想法和应用。本调查的主要贡献可总结如下。

- 对于的，我们提出了一个整体的分类法框架
从数据中心和模型中心的角度看新出现的SFDA设置。本调查通过提供对最新的SFDA方法和应用的及时和全面的总结，填补了现有文献中的空白。
- 我们模块化了30多个有代表性的作品
并比较在最广泛使用的分类数据集上的结果，i。e.，办公室-31，办公室-家庭和VisDA。对不同成分的组合进行可视化和比较分析，对SFDA的进一步研究具有指导意义。

本调查的其余部分的结构如下。在第2节中，我们将介绍与SFDA相关的符号和初步知识。第3节和第4节分别提供了以数据为中心和以模型为中心的SFDA方法的全面回顾。第5节对三个主流分类数据集上现有的SFDA方法进行了比较。第6节讨论了SFDA的潜在应用，而第7节则提出了关于SFDA的未来方向。最后，我们在第8节中总结了论文。

2概述

在本节中，我们将介绍一些与SFDA相关的符号和初步知识，并简要描述了SFDA方法中的几种设置。

2.1符号和定义

为了文献的一致性，我们使用了尽可能多的与迁移学习[22]和深度领域适应[6]，[29]的调查中相同的符号。我们在表2中总结了它们。下面是一些与SFDA问题密切相关的基本定义。

定义1. Φ （SFDA中的域）一个域通常包含一个数据集和一个相应的标签集L，其中数据集包含实例集X从边缘分布P（X）和相应的维度d中淹没。在SFDA中，源域 $D^S= \{ \{X^S, P(X^S), d^S\}, L^S \}$ 通常是完整的，但请注意

表2
与SFDA相关的符号。

符号	描述
n	实例数
D	领域
X	实例集
d	特征尺寸
$F(X)$	特征向量
$Y_j X$	例如X的预测
全	域空间
L	源标签集
L	损失函数
6	软最大操作
c	类的数量
\tilde{z}	噪声矢量
Θ	模型参数
F	特征提取器
C	分类器
D	域鉴别器
G	生成器
M	要训练的模型
M	模块
B	内存库
u	意思是
a	标准差
E	数学期望
P	边缘分布
Q	查询
K	钥匙
v	价值
$N(u, a^2)$	一个均值为u，方差为a的高斯分布 ²

它只在训练前可用。目标域D的标签集 $t= \{ \{X^t, P(X^t), d^t\} \}$ 不可用，其边际分布也不同于源域。在典型的SFDA中，我们假设是一个封闭的形式，i。e.，源域和目标域的标签空间是相同的。

定义2.（SFDA的任务）给定一个在源域D上训练的模型 $M^S= \{ \{X^S, P(X^S), d^S\}, L^S \}$ ，SFDA的过程包括两个阶段。在第一阶段（训练前），源模型通过标记进行训练

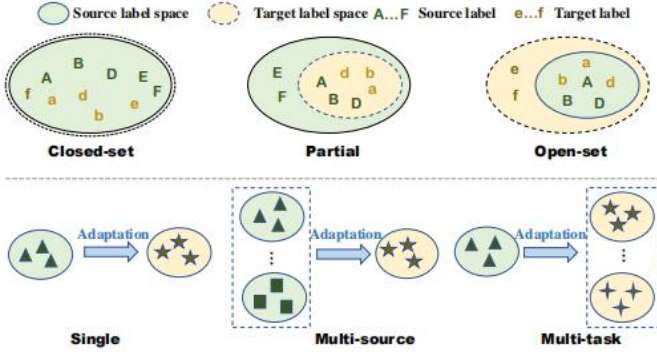


图3. 在SFDA中的不同设置的说明。

在监督学习下的源数据。在第二阶段（自适应）中，源域数据不可用，SFDA的目标是将源训练的模型适应于未标记目标数据的目标域 $\Phi^t = \{X^t; P(X^t); d^t\}$ 也就是说，获得输出 $M(X^t) = P(Y^t|X^t)$ ，其中 $P(Y^t|X^t)$ 为目标数据 X 的预测结果^t。

值得注意的是，上述定义也可能支持一些扩展。对于域的定义，SFDA可能包括多源域[30]、[31]、i.e., $D^S = \{\bigcup_{i=1}^m D_i\}$ 其中 m 是源域的数量，或者可能存在非封闭集情况，如通用源域适应[9]；例如，对于SFDA中的任务定义，在一些扩展的SFDA设置中，在执行任务时也可以使用一小部分标记的目标域数据(i.e., 活动SFDA [32], [33])。我们将在下一节中讨论SFDA的不同变体。

2.2. 在SFDA中的设置的概述

一般情况下，根据源域和目标域特征空间是否相同，域适应可以分为同质域适应和异构域适应。在异构域自适应[34]中，源空间和目标的分布空间和特征空间都可能有所不同，即 $P(X^S) \neq P(X^t)$ 和 $d^S \neq d^t$ ，因此可能需要分布适应和特征空间适应。而在均匀域自适应中，源域和目标域的特征空间是相同的，只进行分布自适应。在现有的SFDA方法中，大多数只涉及同质域自适应，这也是我们在本调查中讨论的重点。

根据源域与目标域之间的标签集对应关系，可以将设置分为闭集、部分集和开集，它们之间的关系如图所示。3. 基于源域和目标域的数量，还存在单源、多源和多任务设置。在本调查中，我们主要关注最一般的封闭集单源SFDA设置，并简要概述了其他设置。

3数据库的方法

这类广泛的基于数据的方法的研究可以分为两种途径，基于两种不同的动机。一方面，考虑源域数据的不可用性，最直观的想法之一是模仿源域数据通过源域模型中隐含的信息，或重建一个中间域或另一个域来弥补源域数据的缺失。另一方面，考虑目标域的无注释，另一类方法可以被视为试图探索未标记的目标域数据中的潜在的数据结构或聚类信息，使单独使用目标域数据独立执行域自适应任务成为可能。在我们的分类中，我们将上述两个方向分别称为基于领域的重建和基于图像的信息提取。下面，我们将分别详细描述每一个。

. 13基于域的重建

这类方法的核心目的是重构一个新的域来监督目标域。一般来说，有三个方向构建一个新领域，一个是生成一个虚拟源域，一个是构建一个扰动目标域健壮的学习，最后一个是将目标域分成源和目标部分，然后执行域内对抗实现对齐。

3.1.1虚拟域生成

在无监督域自适应中，一个典型的范例是在源域上对模型进行监督，同时利用一些技术直接对齐源域和目标域的分布。此过程的总体培训目标可表述为：

$$L_{DAM} = L_{cls}(C(F(X^S)); Y^S) + L_{div}(F(X^S); F(X^t)); \quad (1)$$

其中 L_{cls} 是源域中的监督损失，通常使用交叉熵。 L_{div} 表示用于对齐的标准。然而，在SFDA， X^S 在适应过程中不可用。因此，虚拟域生成方法试图构造一个域来补偿缺乏源数据。以上方程可扩展如下：

$$L_{SFDA} = L_{生成}(C(F(X^V))) + L_{div}(F(X^V); F(X^t)); \quad (2)$$

其中 X^V 表示虚拟结构域和 $L_{生成}$ 表示虚拟域的生成性损失。请注意，该模型已经在源域上进行了预先训练，因此可以通过探索模型的输出来模拟域的分布。

我们可以发现，与等式相比3、SFDA除了关注域之间的对齐外，还应该关注虚拟域生成的质量。由于当虚拟域生成时，SDFA的对齐问题与UDA，e相似。g., VDA-DA [35]用于ADDA[21]，MMD[36]用作




图4. 领域重建方法的概述。

在STDA [37]中的对齐度量中，我们将在本节中集中讨论如何生成虚拟域。从技术上讲，虚拟域可以通过两种方式生成：基于对抗性生成或基于高斯分布。

利用GAN [38]的思想，对抗性的一代可以表示为：

$$L(C; F; D; G) = L_{adv} + L_{反对票}; \quad (3)$$

其中L反对票是用于约束跨域的语义一致性的一致性损失，并且可以包含多个视角。 L_{adv} 表示生成器和域鉴别器之间的对抗性损失，通常基于以下公式：

$$\begin{aligned} \mathcal{L}_{adv}(G) &= \mathbb{E}_{y, \tilde{z}} [\log \mathcal{D}(1 - G(y, \tilde{z}))], \\ \mathcal{L}_{adv}(D) &= \mathbb{E}_{x_t \sim \mathcal{X}_t} [\log \mathcal{D}(x_t)] + \mathbb{E}_{y, \tilde{z}} [\log (1 - \mathcal{D}(G(y, \tilde{z})))] \end{aligned}$$

\tilde{z} 其中表示噪声向量， $G(y; \cdot)$ 表示以预定义的标记y为条件的生成器，这与传统的生成器[39]，[40]不同。

这类方法的重点在于L的设计反对票。3C-GAN [41]是这一领域的开创性工作，对于生成器，它强调了生成的x之间的语义相似性 $v_{\tilde{z}} = G(y; \cdot)$ 和标签y。对于该分类器，提出了一种确定性约束、一种权值约束和一种基于聚类的约束来提高其性能。此外，SDDA [42]提出了一种基于域鉴别器的一致性损失方法，该方法引导特征提取器通过二值分类损失提取域不变特征。CPGA [43]的灵感来自于InfoNCE [44]，并通过添加对比损失为每个类别生成更有代表性的原型。

另一种虚拟域生成的方法是基于高斯分布来模拟源域的分布根据预训练模型中包含的隐知识分布。一般说，主要有两种观点。一种观点是采样标准高斯分布的噪声作为生成器的输入，则虚拟源数据生成过程可以表示为： \tilde{x}

$$\tilde{x} \sim G(\cdot); \quad N(0; 1). \quad (5)$$

基于无数据知识蒸馏的[45]，Liu等人。[11]提出了一种批量归一化的、利用源域模型的BN层中存储的均值和方差的统计损失来建模源域分布。

另一种观点是将源域分布看作是多个高斯分布的混合物。例如，VDM-DA [35]构造了一个高斯混合物

模型表示虚拟域在特征空间中的分布为：

$$D^v(f_v) = \sum_{k=1}^K \pi_k \mathcal{N}(f_v | \mu_k, \sigma^2 I), \quad (6)$$

其中 f_v 代表虚拟的功能和 π_k 表示的混合系数与 $\sum_{k=1}^K \pi_k = 1$ 。为了估计高斯混合模型的参数，VDM-DA根据经验将K设置为类别数，并认为源分类器的权重隐式地包含了每个类别的原型信息，并基于源分类器推导出模型的均值和标准差。SoFA [46]分别对推理过程和生成过程进行建模，并从预测的类中推导出高斯分布的混合物作为参考分布。

然而，对虚拟域使用生成模型不仅成本高昂，而且很难很好地执行域泛化，特别是当底层数据模式复杂得多时。因此，一些方法尝试使用非生成性的方法，e.g.，通过直接从目标域中选择一些可靠的数据来构建一个虚拟源域。一个最常见的想法是，通过将目标域图像输入源模型，认为具有高预测熵的样本更接近源域分布，可以在一定程度上用来表示源域分布。然而，这种方法提出的另一个关键问题是虚拟源域的数据不足的问题。例如，Du等人。[47]发现，可以选择构建虚拟源域的样本数量只有目标域的十分之一，这不足以支持代表整个源域的数据分布。

为了解决这个问题，一系列的方法都集中在如何扩展虚拟源域数据上。Mixup [48]是一种有效的技术，PS [47]将虚拟源域中的样本相互混合，可以表示为：

$$\begin{aligned} \tilde{x}_{s, aug} &= \lambda \tilde{x}_s^i + (1 - \lambda) \tilde{x}_s^j, \\ \tilde{y}_{s, aug} &= \lambda \tilde{y}_s^i + (1 - \lambda) \tilde{y}_s^j, \end{aligned} \quad (7)$$

其中， λ 为混合系数， $\tilde{x}_s^i, \tilde{x}_s^j$ 是通过预测熵从虚拟源域中选择的样本， $\tilde{y}_s^i, \tilde{y}_s^j$ 分别是它们对应的标签。通过这种方法，得到了一个增强的虚拟源域 $\tilde{D}_{aug} = \tilde{D}_s \cup \tilde{D}_{aug}$ 和 $\tilde{D}_{aug} = \{\tilde{x}_{s, aug}; \tilde{y}_{s, aug}\}$ 。相反，UIDM [49]首先在目标域中进行混合，然后不仅在虚拟源域的样本选择中考虑了预测熵，

以及混合操作带来的数据不确定性和退出操作带来的模型不确定性。

除了通过混合来增强数据外，另一个想法是在训练过程中不断地将样本从目标域转移到虚拟源域。Ye等人。[50]提出了一种非线性权值熵最小化损失，以不断降低高置信样本的熵值，同时在训练过程中使低置信样本不受影响，从而得到更可靠的样本。虽然虚拟源域中的样本数量正在增加，但对于一些困难的类别，其虚拟源域的样本可能仍然严重缺乏。ProxyMix [51]提出了这个问题，并使用每个原型的最近邻以及域内混淆构建了一个类平衡的代理源域。

3.1.2 域内对抗性探索

在上一节中，我们介绍了通过生成虚拟域来处理源数据不可用问题的方法，这将SFDA视为一个跨域问题。相反，其他一些方法在目标域内执行二进制分割，然后在保持源模型知识的同时，在两个数据种群之间进行对抗性学习。因此，它实现了目标域内总体数据分布的一致性，这将SFDA视为一个域内对齐。值得注意的是，之前引入的虚拟源域方法在置信度方面与这类方法有一定的灵感，但前者强调如何构建虚拟源域，而后者则以对抗的方式关注域内分布对齐。因此，我们将前者归类为虚拟域重构类。

从技术上讲，域内对抗对齐主要使用不同的分类器和特征提取器进行对抗，这可以看作是传统UDA中双分类器范式对抗方法[52]、[53]、[54]的变体。在这里，我们首先回顾了双分类器范式的通用三步法过程：

- 步骤1来源培训：

$$\min_{\theta_F, \theta_{C_1}, \theta_{C_2}} \sum_{i=1}^2 \mathcal{L}_{cls}(\mathcal{C}_i(\mathcal{F}(\mathcal{X}^s)), \mathcal{Y}^s),$$

其中 \mathcal{L}_{cls} 表示交叉熵损失， \mathcal{C}_1 和 \mathcal{C}_2 重新评价这两个分类器， $\theta_F, \theta_{C_1}, \theta_{C_2}$ 分别为特征提取器和分类器对应的模型参数。

- 步骤2：最大分类器预测差异：

$$\min_{\theta_{C_1}, \theta_{C_2}} \mathcal{L}_{cls}(\mathcal{Y}^s, \mathcal{Y}^s) - \mathcal{L}_{dis}(\mathcal{Y}_1^t | \mathcal{X}^t, \mathcal{Y}_2^t | \mathcal{X}^t),$$

其中第一项与步骤1相同， \mathcal{L}_{dis} 是指两个分类器的预测的差异损失。

- 步骤3：最小化分类器的预测差异：

$$\min_{\theta_F} \mathcal{L}_{dis}(\mathcal{Y}_1^t | \mathcal{X}^t, \mathcal{Y}_2^t | \mathcal{X}^t).$$

我们现在在SFDA设置中回顾这三步过程。对于第一步，通常是对源模型进行训练的

同样地对于第二步和第三步，请使用 \mathcal{L}_{cls} 由于缺少源数据，术语难以处理，源知识不能很好地维护。因此，预测差异项 \mathcal{L}_{dis} 在这种情况下，就会变得不锚定。

为了解决SFDA设置中的上述问题，可以通过冻结一个分类器的参数来保留源特定的分类器，并可以在未标记的目标数据上训练目标特定的分类器。此外，根据源特定分类器的预测置信度或其他标准，可以将目标域分为源相似和源不同样本，从而通过目标特定分类器和源特定分类器对两个数据群体的预测，可以实现域内对抗对齐。在形式上，域内对抗性对齐方法可以推广为以下两个步骤：

步骤1*通过最大化目标特定分类器和目标特定分类器在源不相似样本上的预测差异，同时最小化源相似样本上相同的预测差异：

$$\min_{\theta_{C_t}} \sum_{x \in \mathcal{X}_h^t} \mathcal{L}_{dis}(p^s(x), p^t(x)) - \sum_{x \in \mathcal{X}_l^t} \mathcal{L}_{dis}(p^s(x), p^t(x)),$$

其中 \mathcal{X}_h^t 和 \mathcal{X}_l^t 用 \mathcal{X} 表示目标域中的高置信度（源微粒度）和低置信度（源不同）样本 $\mathcal{X}_h^t \cup \mathcal{X}_l^t = \mathcal{X}^t$ ， $p^s(x)$ 和 $p^t(x)$ 分别表示源特定分类器和目标特定分类器的预测。

步骤2*更新特征提取器，以将目标特征拉到两个分类器的决策边界内：

$$\min_{\theta_F} \sum_{x \in \mathcal{X}^t} \mathcal{L}_{dec}(p^s(x), p^t(x)), \quad (9)$$

其中 \mathcal{L}_{dec} 表示决策损失，以提高特征提取器的泛化能力。

一般来说，提高域内对抗性对齐的效果总共有三个方向，即 \mathcal{L} 的选择 \mathcal{L}_{dis} 和 \mathcal{L}_{dec} ， \mathcal{X} 之间的划分 \mathcal{X}_h^t 和 \mathcal{X}_l^t ，以及网络结构的优化。由于我们总结了域内对抗对齐的一般框架，我们现在讨论在这个框架下的相关方法。

A^2Net [10]是域内对抗对齐的第一个工作，它基于投票策略，通过将源特定的和目标特定的分类器的预测连接在一起并执行Softmax操作来划分目标域。具体地说，如果源特定分类器的投票得分高于目标特定分类器的投票得分，则将被视为类似源特征，反之亦然。值得注意的是，它提出了一种软对抗机制来训练特定目标的分类器和特征提取器，

它可以表示为:

$$\min_{\theta_{c_t}} - \sum_{i=1}^{n_t} \left(\alpha_i^s \log \left(\sum_{k=1}^K p_{(i)k}^{st} \right) + \alpha_i^t \log \left(\sum_{k=K+1}^{2K} p_{(i)k}^{st} \right) \right),$$

$$\min_{\theta_{\mathcal{F}}} - \sum_{i=1}^{n_t} \left(\alpha_i^t \log \left(\sum_{k=1}^K p_{(i)k}^{st} \right) + \alpha_i^s \log \left(\sum_{k=K+1}^{2K} p_{(i)k}^{st} \right) \right),$$

其中 α_i^s 和 α_i^t 分别表示源特定分类器和目标特定分类器的投票得分, $p^{st} = \begin{bmatrix} p^s & p^t \end{bmatrix}^T$ 是 p 的浓度吗 s 和 p^t 激活后。虽然等式的呈现10是dif-从等式的热情8, 它本质上仍然是特征提取器和目标分类器之间的对抗性训练, 所以我们的框架仍然适用。

BAIT [55] 是另一种符合域内对抗对齐范式的典型方法, 该方法使用KL散度作为差异损失, 以及提高两个分类器的输出熵, 表示如下:

$$\min_{\theta_{c_t}} \sum_{x \in \mathcal{X}_h^t} \mathcal{D}_{SKL}(p^s(x), p^t(x)) - \sum_{x \in \mathcal{X}_l^t} \mathcal{D}_{SKL}(p^s(x), p^t(x)),$$

$$\min_{\theta_{\mathcal{F}}} \sum_{i=1}^{n_t} \sum_{k=1}^K [-p_{i,k}^s \log p_{i,k}^t - p_{i,k}^t \log p_{i,k}^s],$$

其中 $D_{SKL}(a, b) = (D_{\frac{1}{2}}(a|b) + D_{\frac{1}{2}}(b|a))$. 值得一提的是, BAIT在其实验中发现, 对于所选择的阈值, 最好将源相似和源不同的集划分为相同的大小, 我们认为这是一个信息的含义。

KL散度是衡量两种分类器之间预测分布差异的相对良好指标, 但它忽略了分类器输出的确定性, 这可能导致模糊的输出问题。D-MCD [56] 和 DAMC [57] 都与此有关并采用CDD距离[58]来测量输出的一致性和确定性。除此之外, 他们还对网络结构进行了一些改进。在D-MCD中, Chu等人。利用模型在训练过程的早期阶段记忆简单样本的倾向, 设计了一个强-弱范式来联合过滤样本, 以避免不正确的高置信度样本。另一方面, DAMC使用具有两个以上分类器的网络结构, 为分类提供更严格的域间隙上界, 并从与类别数量相同得到最优分类器数量。然而, 所有这些额外的网络结构也增加了计算开销。

到目前为止, 关于UDA的两项主要研究方向已经反映在SFDA中。在虚拟域生成类中, 可以使用一些度量标准或基于对抗性学习的策略来对齐虚拟域分布和目标域分布。在域内对抗对齐中, 可以使用双分类器范式的一种变体。这两种方法都表明了SFDA和UDA之间潜在的研究联系。

3.1.3 干扰域监督

这类方法本质上是基于源域特征和目标域特征都来源于一个域不变的特征空间[59], 的假设。e., 源域和目标域实际上是由域不变特征加上一些域偏置因子形成的。从摄动的角度来看, 利用目标域数据对源数据进行语义增强[60], 从而指导模型学习域不变特征是可行的。然后, 在没有源域数据的情况下, 也可以在模型训练过程中对未标记的目标数据添加一些适当的域相关扰动。如果模型能够抵抗这些与域相关的扰动, 就可以使模型获得域不变的特征。如图所示。4(c), 扰动目标域作为对源域的引导, 所以我们将此称为扰动目标域监督。虽然在这一技术路线上的方法仍然很少, 但由于其独特的技术特点, 我们将其作为一个类别与基于领域的重建中的其他两类方法并行。

作为这一类的代表性方法, SOAP [61] 认为该模型的最终目标是找到域不变特征, 并表示的调整方向该模型作为一个向量, 并在UDA和SFDA中反映为:

$$\begin{cases} \vec{\epsilon}(\mathcal{D}^t, \mathcal{D}^I)_{UDA} = \vec{\epsilon}(\mathcal{D}^t, \mathcal{D}^s) + \vec{\epsilon}(\mathcal{D}^s, \mathcal{D}^I), \\ \vec{\epsilon}(\mathcal{D}^t, \mathcal{D}^I)_{SFDA} = \vec{\epsilon}(\mathcal{D}^{t+}, \mathcal{D}^t), \end{cases} \quad (12)$$

其中 \mathcal{D}^I 表示域不变的特征空间, 和 \mathcal{D}^{t+} 是通过添加一个特定于目标的扰动来构造的超目标域吗 \tilde{N}_T 到目标域的样本为 $X_{T+}^i = \beta X_T^i + (1 - \beta) \tilde{N}_T$.

SMT [62] 也基于这个策略, 它可以动态地更新被扰动的目标域。虽然超级目标域的动机很有吸引力, 但构造仍然太简单, e. g., 取目标图像的平均值, 这可能不足以反映目标域的性质。

出于同样的目的, 浮士特[63]解释这个数据扰动[64]不确定性的角度, 首先应用随机增强目标图像, 然后鼓励特征提取器提取一致的特征在目标图像前后扰动的认知不确定性和任意的不确定性。与扰动目标数据不同, VMP [65] 通过变分贝叶斯推理对模型的参数进行扰动, 以在进行模型自适应时保持模型的判别能力。另一方面, AAA [66] 通过设计对抗实例来攻击模型, 将对抗扰动[67]引入域自适应中, 对抗实例的生成过程可以表示为:

$$\tilde{x}_t = x_t + \frac{G(x_t)}{\|G(x_t)\|_2} \epsilon,$$

$$\max_{\theta_G} \frac{1}{n_t} \sum_{i=1}^{n_t} \mathcal{L}_{cls}(\mathcal{C}(\mathcal{F}(\tilde{x}_t)), \hat{y}_t^i), \quad (13)$$

式中, G 为生成器, $|| \cdot ||$ 为欧几里德范数, 在 >0 为控制扰动不会破坏样本的原始语义信息和 y_i^* 是对应的伪标签是 \tilde{x}_t . 作者认为, 如果模型能够抵御这些攻击, 那么模型的泛化能力可以在此过程中得到显著提高. 这种防御过程可以表述为:

$$\max_{\theta_F, \theta_C} \frac{1}{n_t} \sum_{i=1}^{n_t} \mathcal{L}_{cls}(\mathcal{C}(\mathcal{F}(\tilde{x}_t)), \tilde{y}_t^i). \quad (14)$$

一般来说, 这类方法的关键是扰动的设计. 第一点是, 扰动的大小应该是适当的, 这意味着在不破坏数据或模型的原始特性的情况下, 提高了模型的泛化能力. 第二点是, 扰动应该优选地反映目标域的特性, 以完成目标域上的适应任务。

3.2 基于图像的信息提取

一个图像中所包含的信息主要可以分为两部分[68]: 一部分是与图像标签相关的内容信息, 另一部分是通常是特定于领域的风格信息. 邻居聚类从目标图像的内容信息, 建立在观察目标数据本身有一个清晰的结构和聚类, 因此需要相邻节点之间的一致性来增加类内距离和减少类间距离在特征空间, 以减少分类难度, 因为误分类主要出现在模型[69]的决策边界; 图像样式转换从图像的样式信息开始, 在不改变内容信息的情况下将目标图像转换为源样式, 从而使源分类器能够更好地识别它。

3.2.1 社区聚类

邻域聚类的关键思想是, 虽然目标域的特征分布可以与源域的特征分布发生偏离, 但仍可以在特征空间中形成清晰的簇, 同一簇中的特征来自同一类别. 因此, 如果鼓励特征空间中邻居节点之间的一致性, 它将使来自相同集群的特征点能够共同向一个共同类别移动。

G-SFDA [70]是这类工作的先驱, 它提出使用局部结构聚类来进行一致性约束. 其计算方法可表现为如下:

$$\begin{aligned} \mathcal{L}_{LSC} &= -\frac{1}{n} \sum_{i=1}^n \sum_{k=1}^K \log[p(x_i) \cdot \mathcal{B}_S(\mathcal{N}_k)] + \sum_{c=1}^C \text{KL}(\bar{p}_c || q_c), \\ \mathcal{N}_{\{1, \dots, K\}} &= \{\mathcal{B}_F^j | \text{top} - K(\cos(\mathcal{F}(x_i), \mathcal{B}_F^j)), \forall \mathcal{B}_F^j \in \mathcal{B}_F\}, \\ \bar{p} &= \frac{1}{n} \sum_{i=1}^n p_c(x_i), \text{ and } q_{\{c=1, \dots, C\}} = \frac{1}{C}. \end{aligned}$$

从等式LSC首先找到与 x 最相似的顶级 k 特性 i 在特征库 B 中 P 通过计算余弦相似度, 然后约束这些 K 个特征的预测分数的预测一致性 S 带 x_i . L的第二项LSC用于防止退化解[71], [72], 以促进预测平衡. CPGA [43]通过仅约束邻居节点之间的归一化相似性作为辅助损失来简化这个步骤, 这也有助于提高精度。

在此基础上, NRC [73]根据相邻节点是否为最近的邻居, 进一步细化为互惠邻居和非互惠邻居. $i \stackrel{j}{\sim} k$ e., $(j2N) \setminus (i2N)$, 并构建一个扩展的邻域, 以在公共结构中聚合更多的信息, 从而将不同邻域的亲和力加权为:

$$\begin{aligned} \mathcal{L}_N &= -\frac{1}{n_t} \sum_i \sum_{k \in \mathcal{N}_K^i} A_{ik} \mathcal{B}_{S,k}^T p_i, \\ \mathcal{L}_E &= -\frac{1}{n_t} \sum_i \sum_{k \in \mathcal{N}_K^i} \sum_{m \in E_M^k} r \mathcal{B}_{S,m}^T p_i, \end{aligned} \quad (16)$$

其中 A_{ik} 为1, 而 i 和 k 是倒数节点, 否则是 $A_{ik} = r = 0.1$. 同样, 唐等人. [74]在流形上构造语义邻居来描述更完整的几何信息, Tian等人. [75]与伪标记技术相结合, 通过相邻节点的加权平均预测得到结构保留的伪标记. 但是, 以往的方法只考虑了保持相同聚类的一致性 (减少类内距离), 而忽略了不同聚类的差异 (增加类间距离), Aad [76]通过定义两个似然函数来实现这一点:

$$\begin{aligned} P(\mathbb{C}_i) &= \prod_{j \in \mathbb{C}_i} p_{ij} = \prod_{j \in \mathbb{C}_i} \frac{e^{p_i^T p_j}}{\sum_{k=1}^{N_t} e^{p_i^T p_k}}, \\ P(\mathbb{B}_i) &= \prod_{j \in \mathbb{B}_i} p_{ij} = \prod_{j \in \mathbb{B}_i} \frac{e^{p_i^T p_j}}{\sum_{k=1}^{N_t} e^{p_i^T p_k}}, \end{aligned} \quad (17)$$

其中邻居集象牙海岸包括节点 i 的 k 个最近邻和背景集布隆迪包括不是节点 i 的邻居的节点. 一旦得到这两个似然函数, 就可以用负对数似然作为 L 对簇内和簇间施加约束 $i(\mathbb{C}_i, \text{布隆迪}) = -\log \frac{P(\mathbb{C}_i)}{P(\mathbb{B}_i)}$

此外, 邻域聚类也广泛地出现在一个被称为活动SFDA, i 的新环境中. e., 有选择地标记一小部分数据, 这有两个主要好处: (1) 一小部分困难的数据可以通过构造一个邻域图有选择地标记, e. g., ELPT [77]在KNN的基础上选择不可获取的数据; MHPL [32]认为满足邻居混沌、个体不同、类目标属性的数据是最有效的选择; (2) 通过在邻居节点之间的标签传播[78]、[79], 也可以提高目标域的可鉴别性. 总的来说, 邻域聚类方法的关键在于如何从未标记的目标数据中挖掘更多的结构信息, 因为无监督聚类本质上适用于

对于不可用的源数据的SFDA设置，这类方法仍有广泛的范围。

2.23 图像样式翻译

图像样式翻译[80], [81]的目标是将相同的内容呈现成不同的样式，这通常包含两个丢失函数。第一个被称为内容丢失，用于确保翻译前后的语义信息保持一致。另一种称为转移损失，它基于多个中间层的特征统计来执行样式转换。但是，在以前的方法中，大多数特征统计都以Gram矩阵[68]或实例归一化[82]的形式来考虑，这需要访问源域风格的数据，但这在SFDA设置中是不可行的。侯等人。使用平均 $\mu_{\text{存储}}^n$ 信息和方差 $\sigma_{\text{存储}}^n$ 深的将存储在批归一化（BN）层[83]中的第 n 层图像批作为源域的样式代表，提出了一种无源图像样式转换如下：

$$\mathcal{L}_{\text{content}} = \|\mathcal{F}^N(\tilde{x}_t) - \mathcal{F}^N(x_t)\|_2,$$

$$\mathcal{L}_{\text{style}} = \frac{1}{N} \sum_{n=1}^N \|\mu_{\text{current}}^n - \mu_{\text{stored}}^n\|_2 + \|\sigma_{\text{current}}^n - \sigma_{\text{stored}}^n\|_2,$$

其中，源分类器中的特征映射有 N 个层， \tilde{x}_t 表示通过生成器生成的源样式的图像。

另一方面，CPSS [84]专注于通过在训练过程中基于AdaIN [82]增加不同风格的样本来提高模型的鲁棒性。可以得到一个对图像风格变化不敏感的模型，从而具有较强的泛化能力。培训损失可以表示为：

$$\mathcal{L}_{\text{intra}} = \sigma(\tilde{F}_{i,j}) \left(\frac{F_{i,j} - \mu(F_{i,j})}{\sigma(F_{i,j})} \right) + \mu(\tilde{F}_{i,j}),$$

$$\mathcal{L}_{\text{inter}} = \sigma(\tilde{F}_{k,i,j}) \left(\frac{F_{k,i,j} - \mu(F_{k,i,j})}{\sigma(F_{k,i,j})} \right) + \mu(\tilde{F}_{k,i,j}), \quad (9)$$

其中 L 内部的和 L 埋表示 k 个图像之间的图像内样式交换和图像间样式交换。 $\tilde{F}_{i,j}$ 和 $\tilde{F}_{k,i,j}$ 表示提供样式特征的打乱补丁，一个图像可以被划分为 $n_h \times n_w$ 补丁程序如下：

$$F = \begin{bmatrix} F_{1,1} & \cdots & F_{1,n_w} \\ \vdots & \ddots & \vdots \\ F_{n_h,1} & \cdots & F_{n_h,n_w} \end{bmatrix}$$

与CPSS类似，SI-SFDA [85]通过随机屏蔽一些黑色背景的补丁来模拟医学图像分割中损坏图像的学习表示。如何更好地利用BN层也是这类方法的一个关注点，石井等人。[86]通过将BN层中的统计信息与目标域分布对齐来隐式地实现样式转换。到目前为止，这类方法仍然相对少见，而且主要出现在语义分割中。

4 基于模型的方法

与专注于数据生成或探索数据属性的基于数据的方法不同，基于模型的方法将模型分离为几个子模块，然后调整其中一些参数以进行领域适应。在这一类中，自我训练是最主要的范式，甚至在整个SFDA研究中最流行的范式。自训练方法大多使用辅助模块来提高模型的鲁棒性，并与其他方法结合保持源域知识，我们将它们分别分类，以反映我们模块化方法的意图，以便在本调查中获得明确的见解。

4.1 自我培训

由于对源数据的监督是不可用的，自我训练，也称为自我监督学习，利用模型对未标记目标域的预测，以自我监督的方式细化模型。在SFDA中，大多数的自训练方法都是基于伪标记、熵最小化和对比学习的思想来进行的。

4.1.1 伪标签

在没有监督的情况下，最直观的想法是根据源模型的预测对目标样本进行标记，然后根据这些伪标签进行自监督学习，e.g., 拍摄[7]。具体来说，这个过程可以分为三个步骤：**第一步原型生成**类原型基于一些高自信样本或所有样本，**第二步Pseudo标签分配**是指定伪标签通过其他样本和类原型之间的距离或相似性，**第三步伪标签过滤**最后过滤掉一些噪声标签保持标签的纯度。值得注意的是，这一过程中的第一步和第三步都不一定存在。例如，一个样本可以直接用源分类器预测的最可能的类进行伪标记，但我们认为它们彼此之间有紧密的关系。我们将在下面更详细地扩展每个步骤。

原型生成。最简单的方法之一是通过自熵[87], [88], i 来选择类原型。e., 在每个类中选择自熵大于一定阈值的样本。丁等人。[51]将源分类器的权值定义为类原型，发现其平均精度高于采用熵准则。但是，以这种方式选择的类原型可能没有代表性。同样，一些方法[77]、[89]受到主动学习的启发，认为具有较高自由能的目标样本更能代表目标域分布，可以作为类原型。另一种流行的方法是基于Deep集群[93]计算各类的质心[7]、[90]、[91]、[92]，其表述如下：

$$c_k = \frac{\sum_{x_t \in \mathcal{X}_t} \delta_k(\mathcal{F} \circ \mathcal{G}_t(x_t)) \mathcal{G}_t(x_t)}{\sum_{x_t \in \mathcal{X}_t} \delta_k(\mathcal{F}_t(x_t))}, \quad (20)$$

其中 c_k 表示第 k 类的质心， δ_k 表示软最大运算中的第 k 个元素。最近的一些

作品[51], [94]认为, 只使用一个原型并不能完全描述这个类, 所以在每个类中生成多个原型。一般来说, 这个步骤的目的是获得一个类原型 p_k 它可以表示目标域中每个类别的分布。

伪标签分配。一旦得到类原型, 每个样本就可以通过与不同类原型的相似性或距离进行比较得到伪标签:

$$y \in \mathcal{L}_k = \arg \min_{p_k} \text{mipse}(G(x_t), p_k), \quad (21)$$

其中 Lpse 表示如何给出伪标签的度量函数。请注意, 当没有生成类原型时, 方程将退化为

$$y \in \mathcal{F}_k = G(x_t = \arg \min_{p_k} \text{mit}), \quad (22)$$

其中, 伪标签直接由模型输出中最自信类别分配。此外, 伪标记的方法也值得讨论。在SHOT [7]的开创性工作中, 在分配伪标签之前先触摸所有的数据是很耗时的。在此基础上, BMD [91]提出了一种动态伪标签策略, 在域自适应过程中更新伪标签。沈等人。[95]只标记目标域的一个子集, 以确保准确性。在这个标签过程中, 如何保持类别之间的平衡也是一个主要问题。Qu等人。[91]利用多实例学习[96], [97]的思想, 形成了一个平衡的全局抽样策略。你等人。[98]设置了类别特定的阈值, 以保持类别之间的数量尽可能一致, Li等人。[99]注意到该模型可能偏向于大多数类别, 因此提出了一种具有二次标签校正的不平衡SFDA策略。

伪标签过滤。由于域移的存在, 模型的输出不可避免地包含噪声。e., 错误的伪标签, 如图所示。5. 因此, 假标签滤波[56]、[87]、[100]和有噪声的标签学习[94]、[101]、[102]是提高伪标签精度的两个重要方向。假标签过滤主要是通过设计一些合理的机制来拒绝不可靠的伪标签。一种是设计一个特定的规则机制, 如Kim等人。[87]提出了一种端到端过滤机制, 只有当样本与最相似类原型的距离小于与第二类相似原型的距离时, 才能识别样本可靠; 另一种是设计一个优化的网络机制来执行过滤, 如Chu等。[56]利用了弱模型更有可能识别硬样本[103]的优势, 并提出了一个额外的未经训练的弱网络来过滤错误的伪标签。杨等人。[100]研究了负学习的稳定性, 并提出了一种多类负学习策略来自适应地学习伪标签选择的过滤阈值。另一方面, 噪声标签学习不再仅仅是过滤错误的伪标签, 而是从噪声标签中学习有用的信息进行自细化。SHOT++ [102]是SHOT [7]的扩展, 试图通过MixMatch [104]来提高高置信样本和低置信样本之间的信息传播的可靠性。




图5. 在伪标记方法中的过程的说明。带有不同颜色的圆圈表示不同类别的样本。带有实心边距的圆圈表示具有伪标签的样本（边距颜色和填充颜色之间的不匹配表示错误的伪标签），三角形表示类原型。首先根据样本在特征空间中的分布情况生成类原型，然后根据类原型为每个样本分配伪标签，最后对有噪声的标签进行过滤。特别是，有些方法在第一步中根据结果再次调整类原型的位置。

NEL [94]将集成学习[105]、[106]引入SFDA设置, 首先基于输入和反馈对目标域样本进行多角度的数据增强, 然后使用跨多个版本的负集成学习来细化伪标签。从伪标记方法的整个过程来看, 伪标签滤波是提高伪标记精度的关键步骤, 但它也带来了额外的资源开销, 因此有效的伪标签滤波技术仍值得讨论。

4.1.2 熵最小化

熵最小化在半监督学习[107]、[108]和无监督学习[16]、[109]方法中有着广泛的应用, 并首次被引入SFDA

由[7]设置。以往的无监督域自适应主要是通过对齐源域和目标域的特征分布来提高模型在目标域的自适应能力, 但如果没有源域数据, 这是不可行的。因此, 另一种想法是直接从结果开始, 假设已经获得了一个具有自适应能力的模型, 那么每个样本的模型输出就应该是确定性的, i. e., 熵最小化, 这个理想的结果约束可以反过来指导模型的优化。熵最小化损失可以表示为:

$$\mathcal{L}_{ent} = -\mathbb{E}_{x_t \in \mathcal{X}_t} \sum_{k=1}^K \delta_k(p_t(x_t)) \log \delta_k(p_t(x_t)), \quad (23)$$

其中 p_t 表示模型对样本 x 的预测 t . 由于熵最小化损失很容易实现, 可以很容易地结合其他方法如伪标记方法作为损失函数, 图像分类在被动设置, 图像分割、医学图像分析和盲图像质量评估迅速采用, 它已经迅速采用图像分类[110], [111], 图像分割[12], [112],

在SFDA设置下的医学图像分析[113]和盲图像质量评估[114]。然而，一些工作[115]，[116]发现，熵最小化损失可能在训练过程中导致一个平凡的解，i.e.，所有的预测都偏向于某一类别，所以批熵最大化损失也可以用来确保预测的多样性：

$$\mathcal{L}_{div} = \sum_{k=1}^K p_k \log p_k, \quad (24)$$

其中 $p_k = \frac{1}{n} \sum_{t=1}^n \mathbb{1}_{\hat{y}_t = k}$ ，是为了积累出去—首先按类放在一个批中，然后执行softmax操作。原因是在一批内，每个类别的样本数量应该平衡，使均匀分布具有最大熵值。在许多SFDA方法中，等式23和等式24个合并形成信息最大化损失：

$$\mathcal{L}_{im} = \mathcal{L}_{ent} + \mathcal{L}_{div}. \quad (25)$$

基于 \mathcal{L}_{im} ，艾哈迈德等人。[31]对多源域设置中的不同源域进行加权，得到加权信息最大化，Mao等人。[111]将邻居节点信息合并到图的自适应中。然而，除了信息最大化后，目前基于熵最小化的创新相对缺乏，更多的方法只是直接将其作为辅助损失来提高精度。熵最小化的关键是从结果如何约束模型的输出目标域从不同层次如个人和整体，确定性和多样化，等等，输出更合理可能是一个主题值得更深入和详细的未来。

4.1.3对比学习

自监督对比学习[117]，[118]是无监督表征学习的常用方法，它侧重于通过在收集正对的同时增加负对之间的距离来学习鉴别表征。该方法的特点是对同一样本构建正、负样本对，主要可分为基于记忆库的[119]、基于编码器的[117]和基于小批量的[120]、[121]。一个最典型的对比损失是InfoNCE损失[44]，[117]：

$$\mathcal{L}_{Info} = - \sum_{v^+ \in V^+} \log \frac{\exp(u^T v^+ / \tau)}{\exp(u^T v^+ / \tau) + \sum_{v^- \in V^-} \exp(u^T v^- / \tau)}, \quad (26)$$

6) 其中 V^+ ， V^- 分别为相同样本 u 的正、负对集合， τ 为温度参数。在无监督域自适应中，通常以目标域样本为关键值，然后以源域样本为查询，进行正、负样本对的构造。但是，后者在无源代码设置中是不可用的，因此如何构造可以代表源代码域的查询是这类SFDA的中心问题

方法，主要可分为3种方法。第一种方法是使用源分类器的权重作为每一类源样本[90]的原型特征：

$$\mathcal{L}_{cdc}^1 = - \sum_{m=1}^M \mathbb{I}_{\hat{y}_u = m} \log \frac{\exp(u^T w_s^m / \tau)}{\sum_{j=1}^M \exp(u^T w_s^j / \tau)}, \quad (27)$$

其中分类器的权重为 $W_s = [w_{ss}^1, \dots, w_s]$ ， $\mathbb{I}_{\hat{y}_u = m}$ 是目标样本 u 上的伪标签指标矩阵。类似地，[43]使用生成的原型进行对比学习，并引入减重来提高伪标签的可靠性。第二种方法是增加当前一批对比匹配[10]中的正对的相似性：

$$\mathcal{L}_{cdc}^2 = - \log \frac{\exp(s_{ij})}{\sum_{v=1}^b \mathbb{I}_{v \neq i} |\gamma_{iv}| \exp(s_{iv})}, \quad (28)$$

s 在哪里 $i, j = [a(p_i)]^T a(p_v)$ 表示第 i 个样本和第 v 个样本对其模型输出 p 的软最大操作的相似性 i, p_v ， V_{iv} 是一个阈值函数，用于确定这两个样本是否属于一个类。最后一类方法保留了一个存储库来存储历史模型的输出，从而构建了正、负样本对[122]，[123]。HCID [122]使用当前模型将当前批处理的样本编码为查询 $q^t = M^t(x_q)$ ，然后使用历史模型将以前存储的示例编码为键 $k_n^{t-m} = M^{t-m}(x_{kn})$ ：

$$\mathcal{L}_{cdc}^3 = - \sum_{x_q \in X_t} \log \frac{\exp(q^T k_+^{t-m} / \tau) \gamma_+^{t-m}}{\sum_{i=0}^N \exp(q^T k_i^{t-m} / \tau) \gamma_i^{t-m}}, \quad (29)$$

其中， N 为存储的密钥数， V 为用于度量密钥可靠性的参数，其中一个实现是分类熵。一般来说，这类无源代码方法的部分处理过程类似于基于数据的SFDA的基本思想，i.e.，使用生成或非生成的方法来补偿缺失的源数据。

4.2自我注意

在计算机视觉任务中，定位对象区域在领域自适应[124]中起着重要的作用，但传统的CNN模型更倾向于捕获特定领域的局部信息，如背景信息，这可能对聚焦我们真正关注的对象没有帮助。因此，在SFDA设置中引入了自注意机制[125]、[126]：

$$\mathcal{L}_{Attn_{self}}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V, \quad (30)$$

其中 Q 、 K 、 V 分别表示查询、键和值， d_k 是 K 的尺寸。为了解源域中的上下文丢失问题，一些方法[77]、[112]、[124]直接装备了传统的自注意模块

特征提取器平衡30也可以扩展与跨域注意[127]:

$$\mathcal{L}_{Attn_{cross}}(Q_s, K_t, V_t) = softmax(\frac{Q_s K_t^T}{\sqrt{d_k}}) V_t, \tag{31}$$

其中Q_s是来自源域，K_t和V_t来自目标域，它们一起形成一个样本对。在此基础上，CADX [128]将目标域图像划分为支持的图像和来源设置下的图像查询图像，改进原始的补丁补丁操作，以捕获整体表示，减少计算负担。此外，一些方法[11]、[129]进一步从空间注意和通道注意的角度处理特征，以丰富表征的上下文语义。目前，基于注意力的SFDA方法仍然相对罕见，特别是基于变压器的SFDA方法。

5比较

由于分类任务构成了现有的无源域自适应方法的主体，我们在本节中在三个最广泛使用的分类数据集上比较了目前领先的SFDA方法。特别是我们根据第3节和第4节对这些方法进行模块化，以反映不同模块的有效性。

5.1比较数据集

本文中使用的分类数据集包括数字[39]、VisDA-C [130]、Office-31 [131]、Office-Home [132]和域net[133]，我们将统计数据汇总在表中。3. 然而，由于数字数据集的改进空间很小（[7]为98.9%），以及域网数据集的困难，其他三个数据集在社区中更受欢迎。因此，我们主要总结了在这三个数据集上的实验结果，以代表大多数。以下是这三个数据集的详细信息。

Office-31是视觉传输学习的主要基准数据集，它包含了办公环境中常见的31种目标对象的4,652张图像，如笔记本电脑、文件柜、键盘等。这些图片主要来自亚马逊（在线电子商务图像）、网络摄像头（由网络摄像头拍摄的低分辨率图像）和DSLR（由DSLR拍摄的高分辨率图像）。亚马逊数据集中有2817张图像，平均每个类别90张图像，一个图像背景；网络摄像头数据集中有795张图像，图像显示出显著的噪声、颜色和白平衡伪影；DSLR数据集中有498张图像，每个类别有5个对象，每个对象从不同的角度平均拍摄3次。

Office-Home是一个域适应的基线数据集，它包含4个域，每个域由65个类别组成。这四个领域分别是艺术（以绘画、绘画、装饰等形式呈现的艺术图像），剪贴画（剪贴画图像的集合）、产品（无背景的对象图像和真实世界（用常规照相机拍摄的对象图像）。它包含15500张图像，平均平均值为

表3
在SFDA中的数据集的统计数据。

数据集	领域	样品	类
数字	SVHN (S)	1797	10
	MNIST (M)		
	USPS (U)		
办公室	亚马逊 (A)	4652	31
	Dslr (D)		
	Webcorn (W)		
办公用房	艺术形象 (Ar)	15500	65
	剪贴画 (Cl)		
	产品图像 (Pr)		
	真实世界图像 (Rw)		
VisDA-C	真的合成的	207785	12
域网	Clipart (clp)	569010	365
	Infograph (inf)		
	涂漆 (pnt)		
	Quickdraw (qdr)		
	实 (rel)		
	草图 (skt)		

大约70张图片，每个类别最多99张图片。

VisDA-C是一个用于从模拟器到现实环境的领域适应的大规模数据集。它由三个公共数据集共享的12个公共类组成：加州理工学院256(C)、ImageNet ILSVRC2012 (I)和PASCALVOC2012 (P)。源域样本和目标域样本分别是通过渲染三维模型和真实图像生成的合成图像。

为了更好地表示每种方法中包含的模块，我们将SFDA方法分为四类：基于领域的重建（DR）、基于图像的信息提取（IIE）、自我训练（ST）和自我注意（SA）。更精细地，我们将这四种方法分为9个模块，分别是虚拟域生成（Mvdg）、域内对抗对齐（Miaa）、扰动域监督（Mpds）、邻域聚类（Mnc）、图像风格转换（Mist）、伪标记（Mpl）、熵最小化（Mem）、对比学习（Mcl）和自我注意（Msa）。

5.2比较结果

我们总结了表中的办公室、办公室-家庭和VisDA-C数据集的分类精度结果。4、表5和表6。值得注意的是，所有的方法都被统一地设置为单源齐次闭集无源域自适应，我们引用了本文中给出的最佳结果。在表中，我们提供了仅源模型[134]（办公室上的ResNet-50和VisDA-C上的ResNet-101）和目标监督模型的准确性，然后将2020年、202021年和2022年的工作从上到下分割水平线。我们对比较结果的分析如下。

关于SFDA的工作量正在迅速增加。自2020年以来，关于SFDA研究的论文数量呈爆炸式增长趋势。在三个

表4
在Office-31数据集（ResNet-50）上的无源域自适应方法的分类精度（%）比较。

方法	根源目标	博士	三、	ST	萨	模块	A！W	D！W	W！D	A！D	D！A	W！A	平均。
仅限来源的 [134]	-----	68.4	96.7	99.3	68.9	62.5	60.7	76.1					
目标监督 [102]	-	-	-	-	-	-	98.7	98.7	98.0	98.0	98.7	86.0	94.3
拍摄 [7]	/ Mpl+命令	90.1		98.4		99.9	94.0		74.7		74.3	88.6	
3C-GAN [41]	/ 苗亚	93.7		98.5		99.8	92.7		75.3		77.8	89.6	
诱饵 [55]	/					苗亚	94.6	98.1	100.0		92.0	74.6	75.2
SHOT++ [102]	/ Mpl+命令	90.4		98.7		99.9	94.3		76.2		75.8	89.2	
金等人。 [87]						/ Mpl	91.1	98.2		99.5	92.2		71.0
71.2	87.2												
A2净 [10]	/ 苗亚+麦克尔	94.0		99.2		100.0	94.5		76.7		76.1	90.1	
NRC [73]	/ Mnc	90.8		99.0		100.0	96.0		75.3		75.0	89.4	
ASL [135]	/ Mpl+命令	94.1		98.4		99.8	93.4		76.9		75.0	89.5	
TransDA [124]	/ Mpl+Msa	95.0		99.3		99.6	97.2		73.7		79.3	90.7	
CPGA [43]	/ Mnc + Mpl + 麦克尔	94.1		98.4		99.8	94.4		76.0		76.6	89.9	
AAA [66]	/ Mpls+ Mpl + 麦克尔	94.2		98.1		99.8	95.6		75.6		76.0	89.9	
VDM-DA [35]	/ Mvdg+命令	94.1		98.0		100.0	93.2		75.8		77.1	89.7	
hcl+拍摄 [122]						Mpl + 麦克尔	92.5	98.2	100.0	94.7	75.9	77.7	89.8
AaD [76]	/ Mnc	92.1		99.1		100.0	96.4		75.0		76.5	89.9	
U-SFAN [136]	/ Mvdg+命令	92.8		98.0		99.0	94.2		74.6		74.4	88.8	
CoWA-JMDS [137]	/ Mvdg+ Mpl	95.2	98.5	99.8	94.4	76.2	77.6	90.3					
CDCL [90]	/ Mpl+麦克尔	92.1		98.5		100.0	94.4		76.4		74.1	89.3	
D-MCD [56]	/ 苗亚+ Mpl	93.5	98.8	100.0	94.1	76.4	76.4	89.9					
BMD + SHOT++ [91]	/ Mpl+命令	94.2		98.0		100.0	96.2		76.0		76.0	90.1	
ProxyMix [51]	/ Mvdg+ Mpl	96.7	98.5	99.8	95.4	75.1	75.4	85.6					
UTR [138]	/ Mpl	93.5		99.1		100.0	95.0		76.3		78.4	90.3	
SCLM [74]	/ Mnc + Mpl	90.0		98.9		100.0	95.8		75.5		76.0	89.4	
Jing等。 [65]	/								Mpls	93.3	98.6	100.0	
96.2	75.4		76.9		90.0								
Kundu等。 + SHOT++ [139]	/ Mvdg+ Mpl	93.2	98.9	100.0	94.6	78.3	78.9	90.7					

在数据集上，SFDA方法的最高准确率仅为3.6%（Kundu等。 + SHOT++ [139] [140] on Ofiice），2.7%（办公家庭的TransDA[124]）和0.9%（BMD + SHOT++ [91]在VisDA-C）低于目标监督下的准确性（神喻）。在某种程度上，SFDA在工作数量和准确性方面都优于无监督领域自适应方法，这不仅反映了该领域的巨大潜力，也表明需要进行全面的SFDA调查。

自我训练仍然是目前最流行的研究方向。大多数的SFDA方法都涉及到自我训练的策略。此外，熵最小化[7]、[63]、[91]、[102]、[136]作为辅助损失可以很容易地与大多数SFDA方法相结合，以提高目标域表示的可别性。此外，对比学习[10]、[43]、[66]通常与伪标记模块一起发挥域对齐的作用。在没有源数据和目标标签的情况下，通过对目标数据进行伪标记的自监督是最常见的方法。然而，这不可避免地引入了噪声标签和误差积累的问题。在这方面，一些方法将SFDA问题转化为有噪声的标签学习问题[56]，[94]，以提高模型的性能。有一些方法[138]，[140]试图绕过有噪声的标签问题，隐式地规范了目标域的自训练方向，从而取得了令人满意的结果。从三个数据集中的两个数据集上的实验结果来看，精度最高的方法均采用伪标记法

拍摄++[102]作为基线。例如，Kundu等人。[139]在Office上达到90.7%，BMD [91]在VisDA上达到88.7%。这些观察结果表明，伪标记是一种通用和有效的技术，这也是一个强有力的改进基础。

基于领域的重建是一种常用的方法

开发援助特别基金在领域背后的SFDA方法的直觉-基于重构是非常明确的：其目的是重建一个新的源域或目标域，以替代缺失的源域进行监督。在这类方法中，域内对抗对齐方法是第一批方法，如BAIT [55]和3C-GAN [41]。然而，它们的影响并不令人羡慕，可能是因为在目标域选择的源相似样本包含大量噪声，不够代表性，这也是D-MCD [56]针对去噪问题的原因。虚拟域生成的关注正在上升，可能是由于虚拟域生成方法[35]、[51]、[137]、[139]可以与发挥目标域监督作用的自训练方法密切结合，从而进一步提高虚拟域生成效果，e. g.，达到最高的准确率为90.7%（Kundu等。[139]）在办公室31个数据集。

邻域聚类在基于图像的信息提取中似乎是有效的。与图像风格变换方法[141]相比，邻域聚类明显更有效。例如，SCLM [74]在C1！ Ar和C1！ 在办公室里的房车转移任务。原因可能是邻居聚类可以更好地保存底层的结构信息

表5
办公家庭数据集（ResNet-50）上无源域自适应方法的分类精度（%）比较。

方法	博士	三、	ST	萨	模块	Ar !智利	Ar !波多黎各	Ar !Rw	Cl !阿尔	Cl !波多黎各	Cl !Rw	Pr !阿尔	Pr !智利	Pr !Rw	Rw !阿尔	Rw !智利	Rw !波多黎各	平均。
仅源的[134]目标监督 [102]	-	-	-	-	-	34.9	50.0	58.0	37.4	41.9	46.2	38.5	31.2	60.4	53.9	41.2	59.9	46.1
拍摄[7]			/		Mpl + Mem	57.1	78.1	81.5	68.0	78.2	78.1	67.4	54.9	82.2	73.3	58.8	84.3	71.8
诱饵[55]	/				苗亚	57.4	77.5	82.4	68.0	77.2	75.1	67.1	55.5	81.9	73.9	59.5	84.2	71.6
SHOT++ [102]			/		Mpl + Mem	57.9	79.7	82.5	68.5	79.6	79.3	68.5	57.0	83.0	73.7	60.7	84.9	73.0
A2网[10]	/		/		Misa + Mcl	58.4	79.0	82.4	67.5	79.3	78.9	68.0	56.2	82.9	74.1	60.5	85.0	72.8
NRC [73]		/			Mnc	57.7	80.3	82.0	68.1	79.8	78.6	65.3	56.4	83.0	71.0	58.6	85.6	72.2
TransDA [124]			/	/	Mpl + Msa	67.5	83.3	85.9	74.0	83.8	84.4	77.0	68.0	87.0	80.5	69.9	90.0	79.3
G-SFDA [70]		/		/	Mnc + Msa	57.9	78.6	81.0	66.7	77.2	77.2	65.6	56.0	82.2	72.0	57.8	83.4	71.3
CPGA [43]		/	/	/	Mnc + Mpl + Mcl	59.3	78.1	79.8	65.4	75.5	76.4	65.7	58.0	81.0	72.0	64.4	83.3	71.6
AAA [66]	/		/		Mpds + Mpl + Mcl	56.7	78.3	82.1	66.4	78.5	79.4	67.6	53.5	81.6	74.5	58.4	84.1	71.8
PS [47]	/				Mvdg	57.8	77.3	81.2	68.4	76.9	78.1	67.8	57.3	82.1	75.2	59.1	83.4	72.1
AaD [76]		/			Mnc	59.3	79.3	82.1	68.9	79.8	79.5	67.2	57.4	83.1	72.1	58.5	85.4	72.7
U-SFAN [136]	/		/		Mvdg + Mem	57.8	77.8	81.6	67.9	77.3	79.2	67.2	54.7	81.2	73.3	60.3	83.9	71.9
CoWA-JMDS [137]	/		/		Mdg + Mpl	56.9	78.4	81.0	69.1	80.0	79.9	67.7	57.2	82.4	72.8	60.5	84.5	72.5
D-MCD [56]	/		/		Misa + Mpl	59.4	78.9	80.2	67.2	79.3	78.6	65.3	55.6	82.2	73.3	62.8	83.9	72.2
Kundu等。[140]			/		Mpl	61.0	80.4	82.5	69.1	79.9	79.5	69.1	57.8	82.7	74.5	65.1	86.4	74.0
BMD + SHOT++ [91]			/		Mpl + Mem	58.1	79.7	82.6	69.3	81.0	80.7	70.8	57.6	83.6	74.0	60.0	85.9	73.6
ProxyMix [51]	/		/		Mdg + Mpl	59.3	81.0	81.6	65.8	79.7	78.1	67.0	57.5	82.7	73.1	61.7	85.6	72.8
UTR [138]			/		Mpl	59.8	81.2	83.2	67.2	79.2	80.1	68.4	56.4	83.0	73.7	61.2	85.9	73.2
浮士德[63]			/		Mpl + Mem	61.4	79.2	79.6	63.3	76.9	75.2	65.3	59.4	79.0	74.7	64.2	86.1	72.0
DAMC [57]	/		/		苗亚	57.9	78.5	81.1	66.7	77.7	77.9	66.5	54.3	81.5	73.2	58.9	84.7	71.6
SCLM [74]		/	/	/	Mnc + Mpl	58.2	80.3	81.5	69.3	79.0	80.7	69.0	56.8	82.7	74.7	60.6	85.0	73.1
Jing等。[65]	/		/		Mpds	57.9	77.6	82.5	68.6	79.4	80.6	68.4	55.6	83.1	75.2	59.6	84.7	72.8
Kundu等。+ SHOT++ [139]		/	/		Mdg + Mpl	61.8	81.2	83.0	68.5	80.6	79.4	67.8	61.5	85.1	73.7	64.1	86.5	74.5

表6
在VisDA-C数据集（ResNet-101）上的无源域自适应方法的分类精度（%）比较。

方法	博士	三、	ST	萨	模块	水平	bcycl	公共汽车	小汽车	马	刀	mcycl	人	植物	sktbrd	火车	货车	平均。
仅源的[134]目标监督 [102]	-	-	-	-	-	55.1	53.3	61.9	59.1	80.6	17.9	79.7	31.2	81.0	26.5	73.5	8.5	52.4
拍摄[7]			/		Mpl + Mem	94.3	88.5	80.1	57.3	93.1	94.9	80.7	80.3	91.5	89.1	86.3	58.2	82.9
3C-GAN [41]	/				苗亚	95.7	78.0	69.0	74.2	94.6	93.0	88.0	87.2	92.2	88.8	85.1	54.3	83.3
诱饵[55]	/				苗亚													83.0
侯等人。[141]		/	/		薄雾+ 命令	-	-	-	-	-	-	-	-	-	-	-	-	63.5
SHOT++ [102]			/		Mpl + Mem	97.7	88.4	90.2	86.3	97.9	98.6	92.9	84.1	97.1	92.2	93.6	28.8	87.3
金等人。[87]			/		Mpl	86.9	81.7	84.6	63.9	93.1	91.4	86.6	71.9	84.5	58.2	74.5	42.7	76.7
A2网[10]	/		/		苗亚+ 迈克尔	94.0	87.8	85.6	66.8	93.7	95.1	85.8	81.2	91.6	88.2	86.5	56.0	84.3
NRC [73]		/			Mnc	96.8	91.3	82.4	62.4	96.2	95.9	86.1	80.6	94.8	94.1	90.4	68.2	85.9
G-SFDA [70]		/		/	Mnc + Msa	96.1	88.3	85.5	74.1	97.1	95.4	89.5	79.4	95.4	92.9	89.1	42.6	85.4
美国手语[135]			/		Mpl + Mem	97.3	85.3	86.9	70.7	96.4	72.8	93.0	80.1	95.5	78.1	87.7	50.3	82.8
TransDA [124]			/	/	Mpl + Msa	97.2	91.1	81.0	57.5	95.3	93.3	82.7	67.2	92.0	91.8	92.5	54.7	83.0
CPGA [43]		/	/		Mnc + Mpl + Mcl	95.6	89.0	75.4	64.9	91.7	97.5	89.7	83.8	93.9	93.4	87.7	69.0	86.0
AAA [66]	/		/		Mpds + Mpl+ 迈克尔	94.4	85.9	74.9	60.2	96.0	93.5	87.8	80.8	90.2	92.0	86.6	68.3	84.2
VDM-DA [35]	/		/		Mdg+ 命令	96.9	89.1	79.1	66.5	95.7	96.8	85.4	83.3	96.0	86.6	89.5	56.3	85.1
PS [47]	/				Mvdg	95.3	86.2	82.3	61.6	93.3	95.7	86.7	80.4	91.6	90.9	86.0	59.5	84.1
AaD [76]		/			Mnc	97.4	90.5	80.8	76.2	97.3	96.1	89.8	82.9	95.5	93.0	92.0	64.7	88.0
U-SFAN [136]	/		/		Mdg+ 命令													82.7
HCL+SHOT [122]			/		Mpl+ 迈克尔	93.3	85.4	80.7	68.5	91.0	88.1	86.0	78.6	86.6	88.8	80.0	74.7	83.5
CoWA-JMDS [137]	/		/		Mdg + Mpl	96.2	89.7	83.9	73.8	96.4	97.4	89.3	86.8	94.6	92.1	88.7	53.8	86.9
NEL [94]			/		Mpl	94.5	60.8	92.3	87.3	87.3	93.2	87.6	91.1	56.9	83.4	93.7	86.6	84.2
CDCL [90]			/		Mpl+ 迈克尔	97.3	90.5	83.2	59.9	96.4	98.4	91.5	85.6	96.0	95.8	92.0	63.8	87.5
D-MCD [56]	/		/		Misa + Mpl	97.0	88.0	90.0	81.5	95.6	98.0	86.2	88.7	94.6	92.7	83.7	53.1	87.5
Kundu等。[140]			/		Mpl													88.2
BMD + SHOT++ [91]	/		/		Mpl + Mem	96.9	87.8	90.1	91.3	97.8	97.8	90.6	84.4	96.9	94.3	90.9	45.9	88.7
ProxyMix [51]	/		/		Mdg + Mpl	95.4	81.7	87.2	79.9	95.6	96.8	92.1	85.1	93.4	90.3	89.1	42.2	85.7
UTR [138]			/		Mpl	98.0	92.9	88.3	78.0	97.8	97.7	91.1	84.7	95.5	91.4	91.2	41.1	87.3
浮士德[63]	/		/		Mpl + Mem	96.7	77.6	87.6	73.3	95.5	95.4	92.9	83.6	95.3	89.5	87.7	46.9	85.2
DAMC [57]		/	/		苗亚	95.4	86.9	87.2	79.7	94.6	95.7	91.2	84.9	95.7	91.5	81.9	41.7	86.0
SCLM [74]	/		/		Mnc + Mpl	97.1	90.7	85.6	62.0	97.3	94.6	81.8	84.3	93.6	92.8	88.0	55.9	85.3
Kundu等。+ SHOT++ [139]			/		Mvdg + Mpl													87.8

在剪贴画图像。此外，AaD [76]在VisDA上获得了第二高的分类准确率88%，可以作为一个简单但强的基线。

自我关注是很有前途的，特别是基于转换器的SFDA方法。虽然基于自我注意的SFDA方法较少用于图像分类[70]，[124]，主要见于语义分割[11]，[112]，[129]，但基于转换器的方法TransDA [124]在办公家庭数据集上的准确率最高，为79.3%，比第二高的方法[139]高4.8%。这在某种程度上表明，这一点令人鼓舞

将注意力转向目标区域的模型可能对减少域偏移非常有效。然而，TransDA [124]只是将转换器注入到卷积网络中，这可能是一个有趣的话题

变压器如何能更好地与SFDA结合设置

6应用程序

域自适应旨在降低对目标域数据的标记成本，而无源域自适应则进一步保护了源域数据的隐私性。因此，无源域自适应和无监督

领域自适应方法[5]、[6]、[29]在其应用领域中存在高度重叠。目前，大多数SFDA方法都应用于计算机视觉和自然语言处理领域。

6.1 计算机视觉

大多数SFDA方法侧重于图像分类，这是计算机视觉的基本任务。随着VisDA [130]和DomainNet [142]等大规模数据集的普及，对自适应能力的需求也在增加。图像分类还可以扩展到各种应用场景，如真实世界的图像去模糊[143]、跨场景高光谱图像分类[144]和盲图像质量评估[114]。语义分割方法[11]，[12]，[50]，[100]，[129]，[145]，[146]也迅速出现并得到了广泛的应用，包括多器官分割[113]、跨模态分割[147]，[148]，跨设备[100]、跨中心域分割[85]、多部位和寿命脑颅骨分割[77]和道路分割[98]，[149]。其他应用程序包括目标检测[13]、[14]、[62]、人再识别[150]、视频分析[88]、[144]也可以受益于SFDA。

6.2 自然语言处理

无源域自适应在自然语言处理（NLP）中的应用仍然相对有限。NLP的相关设置和研究包括连续学习[151]、[152]和预训练模型[153]的泛化能力。拉帕拉等人。设计了两个任务上的SemEval 2021 Task 10数据集[154]。e.，否定检测和时间表达式识别。苏等人。[33]将自训练[155]、主动学习[156]和数据增强[157]基线扩展到无源设置，以进行系统比较。

6.3 其他相关问题

域泛化（DG）[158]，[159]，使模型在以前未见过的目标域上工作，可以被视为域适应的相关设置，一些无源的DG方法[160]，[161]也出现了，它可以被视为基于数据的SFDA方法的变体。提出了无源零镜头域自适应[162]、[163]，以缓解测试时域自适应[164]中对小批量和类分布的流式数据的需求。Ondrej [128]等人。研究了无前馈无源域自适应，它是无反向传播的，以进一步保护用户隐私和减少开销。也有一些方法将无源域自适应设置与联邦学习[149]、黑盒测试[165]或鲁棒传输[166]结合起来，以满足不同的实际场景。

7 未来研究方向

尽管对无源领域适应的研究快速增长，以及在方法和性能方面的演变，但在SFDA中研究的问题设置和目标仍然有些有限和同质。

具体来说，分类任务主导了SFDA的研究，这在很大程度上超过了SFDA在其他计算机视觉任务上的增长。下面我们将讨论SFDA的研究领域可以扩展。

17. 弱研究线的富集

虽然我们在本文中讨论了许多SFDA方法，但大多数都集中在伪标记上。与图中的分类。2、对抗动域监督、邻域聚类、自我注意特别是基于转换的自我注意机制等方法的研究较少。对比学习[167]和图像风格转换[168]仍然以相对同质和简单的方式构建，值得在各自的领域介绍一些最新的方法[169]，[170]。此外，熵最小化虽然在SFDA中被广泛应用，但大多以熵损失或信息损失的形式直接用作辅助损失，缺乏进一步的创新。总的来说，SFDA在方法论上仍有丰富的丰富空间。

27进一步的理论支持

本-大卫等人。[15]根据源域和目标域的分布散度、模型在源域上的误差和理想联合误差，推导出了期望目标误差的一般UDA理论。然而，在无源设置中，很难测量域散度。目前大多数的SFDA方法都是基于直觉，并在当前的数据集上取得了经验上的成功。梁等人。[7]建议将信息最大化作为实现确定性和分散输出的一种手段。虽然已经有了以伪标记[56]、多源域[30]、[31]和模型平滑度[171]为中心的SFDA理论分析，但 these 方法只适用于特定的方法。因此，普遍适用于SFDA的理论支持是非常有益的。

7.3 更多应用

在计算机视觉任务中，目前的SFDA方法大多侧重于图像分析，而视频数据包含了更多的空间和时间语义信息，这带来了更大的处理挑战。因此，只有少数专门为视频分析设计的方法。此外，无监督领域自适应在自然语言处理[172]、[173]、[174]、时间序列数据分析[175]、[176]、推荐系统[177]、[178]和地球科学[179]，[180]中发现了许多应用。然而，这些应用还没有扩展到无源设置，这表明SFDA可能实现其在这领域的潜力。

47个综合数据集和评价

目前用于SFDA评估的大多数数据集都是平衡的类别和干净的数据，然而，一些SFDA研究强调了不平衡类别[99]和噪声[166]对模型精度的显著影响。此外，一些现有的数据集也受限于在